

UMA BREVE ANÁLISE DA PREVISÃO DO PIB PER CAPITA DE ALAGOAS EM RELAÇÃO AOS ESTADOS DE PERNAMBUCO E SÃO PAULO PELO MODELO ARIMA

Cayo Luca Gomes Santana
Tamiris Nataly da Silva Araújo

Universidade Federal de Alagoas
Faculdade de Economia, Administração e Contabilidade
Curso de Ciências Econômicas

RESUMO

O artigo a seguir apresenta a previsão de dados do PIB per capita a preços constantes de 2010 do estado de Alagoas em 101 anos em relação aos estados de Pernambuco e São Paulo. Foi utilizado para a previsão o modelo ARIMA ou método de Box-Jenkins. Utilizou-se séries temporais com período entre 1989 e 2019, séries essas obtidas no IPEADATA. Com a análise feita, não foi possível realizar a previsão dos estados de Pernambuco e São Paulo, porém permitiu observarmos a forma como se comportam os modelos de RA(1), MA(1) e de Ruído Branco, este último no caso de São Paulo.

Palavras-chaves: Séries temporais, modelo ARIMA, previsão de dados

ABSTRACT

The following article presents the data forecast of GDP per capita at constant prices for 2010 for the state of Alagoas in 101 years in relation to the states of Pernambuco and São Paulo. The ARIMA model or the Box-Jenkins method was used for the forecast. Time series with a period between 1989 and 2019 were used, series obtained from IPEADATA. With the analysis carried out, it was not possible to forecast the states of Pernambuco and São Paulo, but it allowed us to observe the way in which the RA(1), MA(1) and White Noise models behave, the latter in the case of São Paulo.

Keywords: Time series, ARIMA model, data forecast

JEL code: C01, C1, C22

1. INTRODUÇÃO

Alagoas tem sua economia pautada historicamente na cana-de-açúcar, com seu setor industrial composto majoritariamente por usinas açucareiras, fábricas de beneficiamento de algodão e fábrica de tecidos. Dessa forma, o estado apresenta um desenvolvimento pequeno frente a outros estados. Apesar de setor sucroalcooleiro ter gerado um impulso na economia alagoana durante os anos 70, o setor sofreu uma grave crise na década de 90 devido à forte redução de incentivos. Entretanto, mesmo após a crise do setor, Alagoas continua focando sua economia na cana, sendo o maior produtor do Nordeste e o sétimo maior do Brasil, acordo com dados do IBGE de 2019.

Pernambuco, apesar de também possuir sua economia historicamente focada na cana – e esta ainda se mantendo forte no estado –, desenvolveu outros setores, como a fruticultura e os setores portuário e tecnológico, levando a uma contribuição ao cenário econômico da região. Desta maneira, a projeção futura do cenário de Pernambuco está ligada ao seu desenvolvimento industrial. Já São Paulo, durante o século XIX, ao passar pela transição da exportação de açúcar para o café, se tornou uma das maiores produtoras e exportadoras de café. No final do mesmo século, houve o surgimento das indústrias têxtil, de alimentos e vestuário devido ao bom desempenho com o café. Após o colapso do setor cafeeiro, as indústrias, e setores como: comércio e serviços, assumiram o comando da economia paulista, tornando o estado uma das regiões mais destacadas do mundo no quesito agrícola e industrial.

Segundo os dados do IBGE de 2019, o estado de Pernambuco ocupa o 1º lugar no ranking de PIB per capita do Nordeste, enquanto que São Paulo ocupa o 1º lugar do Brasil. Alagoas ocupa a 24ª colocação no ranking nacional e em 6º na região nordeste.

Tendo em vista a história econômica dos três estados e a situação em que se encontram em relação ao PIB per capita no país, surge a problemática do processo de desenvolvimento do estado alagoano e a necessidade de realizar uma análise de previsão para saber se há possibilidade de um dia Alagoas alcançar o patamar de desenvolvimento proposto nos estados citados.

Acredita-se que ao realizar a previsão, será possível encontrar o ponto em que o PIB per capita de Alagoas atinge os valores recentes em até 101 anos, e o artigo em questão tem como motivação obter a confirmação da hipótese levantada.

O presente trabalho tem como objetivo geral a previsão do PIB per capita (a preços de 2010) de Alagoas para os próximos 101 anos, e como objetivo específico a comparação entre os dados previstos com o último valor da série temporal escolhida dos estados citados anteriormente, para que assim seja possível identificar se a economia alagoana, em algum ponto futuro, poderá se equiparar a estes.

Foi utilizado nesse trabalho o *software* RStudio e aplicado o modelo de previsão de séries temporais não estacionárias ARIMA, com os dados de PIB per capita a preços constantes de 2010 dos estados de Alagoas, Pernambuco e São Paulo em uma série temporal datada de 1989 a 2019, baixados do site IPEADATA. Também foi realizada pesquisa bibliográfica em outros sites, como IBGE, e livros, como o de Econometria Básica, do Gujarati.

O artigo está dividido em: metodologia e base de dados, em que será possível discorrer sobre os procedimentos metodológicos realizados, a especificação econométrica utilizada e melhor explicar as fontes de dados; resultados e discussão, onde será realizada uma análise preliminar dos dados utilizados, fazendo uso da estatística descritiva, e a análise econométrica, onde será explicado o modelo ARIMA aplicado aos dados baixados previamente; conclusões, em que será feito o encerramento do trabalho e retomando o que foi apresentado anteriormente; referências bibliográficas; em que será explicitado todos os sites, livros e dados obtidos para a realização do trabalho em questão.

2. METODOLOGIA E BASE DE DADOS

2.1. Procedimentos metodológicos

O trabalho se aplica como uma pesquisa aplicada e descritiva, com uma abordagem quantitativa e econométrica, utilizando-se de pesquisa documental para a complementação do desenvolvimento da pesquisa.

Em primeiro lugar, foi realizada uma pesquisa documental para encontrar o tema proposto para este artigo. Foi executado o esqueleto do documento encontrado com novas variáveis para a obtenção de novos resultados.

Foram selecionadas três séries temporais com um período de 30 anos (1989-2019), baixadas a partir do banco de dados IPEADATA, na utilização da previsão do modelo ARIMA, o qual será maior detalhado posteriormente. O modelo em questão foi executado no *software* RStudio.

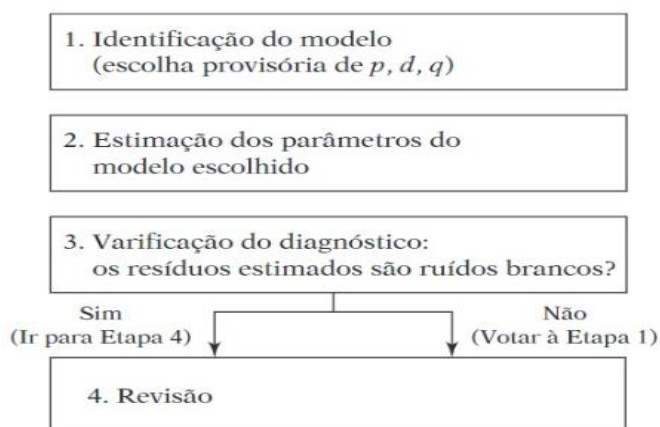
Em seguida, os dados foram importados para o software e foram realizados os comandos para que a previsão fosse realizada. Após o final da previsão, foi realizada uma comparação de dados obtidos, de acordo com o plano descrito nos objetivos na introdução desse trabalho.

2.2. Especificação econométrica

Série temporal é a realização finita de um processo estocástico (um conjunto de variáveis ordenadas no tempo t), ou seja, são conjuntos de dados onde o tempo guia todas as outras variáveis. Ao analisar uma série temporal, é preciso identificar as características do processo estocástico para conseguir especificar e estimar um modelo estatístico e prever valores futuros.

Desta maneira, a regressão clássica é frequentemente insuficiente para explicar a dinâmica de uma série temporal. O modelo ARIMA, ou *Autoregressive integrated moving average* (Modelo auto-regressivo integrado de médias móveis), representa uma generalização de um modelo ARMA (modelo auto-regressivo de médias móveis), e serve como uma forma de prever pontos futuros na série. O modelo ARIMA também é conhecido como método de Box-Jenkins. Esse modelo é frequentemente utilizado como ARIMA(p, d, q), sendo (p, d, q) a ordem do modelo. Segundo Pindyck e Rubinfeld, a aplicação desse modelo é feita em quatro etapas: identificação do modelo, estimação dos parâmetros, checagem do diagnóstico e previsão.

Figura 1 – Passos para a realização do modelo ARIMA



Fonte: Gujarati

O primeiro passo consiste em determinar os filtros (p, d, q) e a ordem que melhor representa, porém é necessário realizar um teste de estacionaridade anteriormente: se a série for estacionária, a ordem de integração é 0, não precisando de diferença para torna-la estacionária. Caso ela for não-estacionária, diferenciações serão necessárias, com o d = 1. Nesse processo, faz-se o uso do teste de raiz unitária de Dickey-Fuller (DF) ou o uso da função autocorrelação FAC.

- p é o número de termos auto regressivos;
- d é o número de diferenças; e
- q é o número de termos da média móvel.

Caso d = 0, o modelo é o ARMA(p, q), e caso q = 0, tem-se o modelo AR(p). Em um terceiro caso onde p = 0 e d = 0, tem-se o modelo MA(q). Em uma situação que haja o modelo ARIMA (0, 1, 0), é o passeio aleatório, ou seja, *randomwalk*. No caso que seja (0, 0, 0), tem-se o ruído branco (*whitenoise*), não podendo realizar previsões futuras.

1. Teste de estacionaridade:

- O teste de Dickey-Fuller

Considerando uma série caracterizada pelo processo:

$$Y_t = \theta Y_{t-1} + \varepsilon_t,$$

onde $\varepsilon_t \stackrel{iid}{\sim} N(0, \sigma^2)$

Se $|\theta| < 1$, então o processo é estacionário. Se $|\theta| = 1$, então haverá raiz unitária e será não estacionário. Portanto, o teste de raiz unitária testa de $|\theta| = 1$ ou não.

Primeiramente, é feita a transformação a seguir:

$$Y_t - Y_{t-1} = \theta Y_{t-1} - Y_{t-1} + \varepsilon$$

$$\Delta Y_t = (\theta - 1)Y_{t-1} + \varepsilon_t$$

$$\Delta Y_t = \pi Y_{t-1} + \varepsilon_t.$$

Após isso, testa-se a hipótese nula de que $\pi = 0$. Se $\pi = 0$ e $\theta = 1$, então Y_t possui raiz unitária.

- Função de autocorrelação (FAC ou AFC)

Assumindo estacionaridade fraca, a k-énésima ordem de autocovariância γ_k fica:

$$\gamma_k = cov\{Y_t, Y_{t-k}\} = cov\{Y_t, Y_{t+k}\}$$

A autocovariância de um processo estocástico pode ser apresentada como uma função de autocorrelação ρ_k :

$$\rho_k = \frac{cov\{Y_t, Y_{t-k}\}}{V\{Y_t\}} = \frac{\gamma_k}{\gamma_0}$$

Essa função ajuda a caracterizar o desenvolvimento de Y_t ao longo do tempo e também nos ajuda a achar raízes unitárias, escolher modelos e fazer diagnósticos sobre regressões.

- Função de autocorrelação parcial (FACP ou PACF)

Essa função nos dará a correlação entre a variável no instante t e uma de suas defasagens, retirando o efeito das outras defasagens.

O próximo passo é a estimação dos parâmetros, ou seja, a estimação dos p parâmetros ϕ e dos q parâmetros θ e da variância σ_ε^2 do modelo de regressão:

$$Y_t = \phi_1 Y_{t-1} + \dots + \phi_p Y_{t-p} + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \dots - \theta_q \varepsilon_{t-q}$$

Essa estimação pode ser feita por mínimos quadrados ou por máxima verossimilhança.

O próximo passo é a verificação, a qual vai avaliar o modelo: se é consistente, se possui excesso de parâmetros, se são significativos e se não são correlacionados.

São aplicados alguns testes estatísticos para comprovação de sua validade, como o teste de sobrefixação, o qual consiste na elaboração de um modelo com um número maior ou menor de parâmetros em comparação com o modelo selecionado, cobrindo supostas direções de discrepâncias. Resumindo: o teste tem como objetivo tentar corrigir algum erro que tenha sido cometido na identificação do modelo.

2. Teste de Ljung e Box

É um método que testa a significância conjuntamente das m primeiras autocorrelações dos resíduos.

Ele é dado por:

$$LB(m) = n(n+2) \sum_{k=1}^m (n-k)^{-1} r_k^2(\hat{\varepsilon})$$

3. Teste de Jarque Bera

Pode ser utilizado para verificar a normalidade dos resíduos:

$$JB = \left(\frac{\hat{S} - 0}{\sqrt{6/n}} \right)^2 + \left(\frac{\hat{K} - 3}{\sqrt{24/n}} \right)^2 = \frac{n}{6} \hat{S}^2 + \frac{n}{24} (\hat{K} - 3)^2$$

O último passo é a previsão. Após todos os passos anteriores, o modelo ou modelos selecionados devem ser testados por meio de simulações. O objetivo é prever valores futuros de uma série sujeitos ao menor erro possível. Por esta razão, a melhor previsão seria a que apresenta o mínimo erro quadrado médio.

4. Teste de Anderson-Darling para Normalidade

É um teste estatístico utilizado para verificar se um conjunto de dados é proveniente de uma determinada distribuição de probabilidade. A distribuição que indicar um p -value maior que 0,05 é uma distribuição normal.

Hipóteses:

H_0 : os dados seguem distribuição de probabilidade normal

H1: os dados não seguem distribuição de probabilidade normal

Se o nível de significância for pequeno (menor que 0,05), a hipótese nula é rejeitada. Ele é expresso por:

$$AD = -n - \frac{1}{n} \sum_{i=1}^n (2i-1) [\ln F(X_i) + \ln(1 - F(X_{n-i+1}))]$$

onde n é o tamanho da amostra, F é a função de distribuição acumulada para a distribuição específica e i é i-ésima amostra quando os dados estão ordenados em ordem crescente.

Para pequenas amostras, o valor deve ser ajustado para:

$$AD^* = AD \left(1 + \frac{0,75}{n} + \frac{2,25}{n^2} \right)$$

com o nível de significância p estimado a partir do valor de AD*.

2.3. Fonte de dados

Os dados utilizados (PIB per capita a preços de 2010) foram retirados do IPEADATA à nível regional, selecionando os estados desejados (Alagoas, Pernambuco e São Paulo) e a série temporal (1989-2019). Os dados obtidos podem ser observados na tabela abaixo.

Tabela 1 – PIB per capita de 1989-2019 (a preços de 2010)

PIB per capita de 1989-2019 (a preços de 2010)							
Ano	Alagoas	Pernambuco	São Paulo	Ano	Alagoas	Pernambuco	São Paulo
1989	5.771,64	6.271,02	24.669,82	2005	6.698,91	7.328,85	22.026,09
1990	6.124,53	7.112,02	22.946,71	2006	6.925,50	7.482,57	22.537,26
1991	6.170,06	7.602,29	22.448,51	2007	7.220,84	7.678,14	24.022,32
1992	6.322,64	8.134,34	21.522,99	2008	7.483,17	7.929,56	24.228,75
1993	6.005,57	7.637,47	22.484,18	2009	7.520,51	8.354,89	24.610,89
1994	6.362,69	7.773,51	23.444,73	2010	7.531,40	9.231,65	25.227,67
1995	6.181,75	7.913,60	24.164,32	2011	8.379,17	9.752,25	26.302,35
1996	6.125,00	7.856,83	24.103,16	2012	8.443,04	10.400,66	26.263,48
1997	6.380,10	8.022,11	24.549,69	2013	8.124,04	10.444,67	25.862,33
1998	6.447,20	7.913,07	23.896,24	2014	8.275,50	10.600,44	26.013,76
1999	6.267,79	7.857,97	23.110,03	2015	8.674,83	9.870,20	25.116,87
2000	6.313,35	8.108,68	23.709,27	2016	8.452,50	9.709,26	24.458,44
2001	6.352,80	8.152,15	23.422,84	2017	8.668,32	10.101,46	24.253,28
2002	6.973,16	7.321,53	21.435,91	2018	8.720,28	9.955,48	24.112,47
2003	6.567,96	6.831,60	21.199,30	2019	9.041,85	10.059,15	24.477,22
2004	6.619,07	7.206,92	20.931,07				

Fonte: Elaboração própria

Também foi consultado sites como o IBGE consultar as colocações dos estados no ranking de PIB per capita, como já mencionado anteriormente.

3. RESULTADOS E DISCUSSÃO


3.1. Análise preliminar

O PIB per capita dos estados brasileiros apresenta certa variação regional, com maiores valores nos centros urbanos mais influentes do país - como São Paulo, Distrito Federal e Rio de Janeiro. Os estados da região Nordeste apresentam valores reduzidos quando comparados com as outras regiões do país, e apresenta maior desigualdade quando comparado entre si.

A evolução histórica do PIB per capita para os estados do Nordeste evidencia a dualidade entre crescimento e desenvolvimento econômico. Dos 27 estados do país, os quatro últimos menores PIBs per capita são de estados nordestinos, e Alagoas é o vigésimo quarto colocado. O estado de Alagoas apresentava PIB per capita de R\$ 5771,64 em 1989, aumentando ao longo de 30 anos até atingir a marca de R\$ 9041,85. Pernambuco apresentava R\$ 6271,02 em 1989 e atingiu a marca de R\$10400,66 ainda em 2012, mantendo-se constante desde então. Já São Paulo, o estado mais populoso do Brasil, apresentava PIB per capita de R\$ 24669,81 em 1989, mantendo-se em 2019 no valor semelhante de R\$ 24477,22.

Diante desta série temporal, estimar o crescimento do PIB do estado de Alagoas é não só comparar o crescimento com o de outros estados, mas é também buscar entender quanto o estado se desenvolve em meio ao crescimento.

Gráfico 1 – PIB per capita de Alagoas, Pernambuco e São Paulo




Fonte: Elaboração própria

3.2. Análise econométrica

Para trabalharmos com o processo autorregressivo integrado de médias móveis de maneira efetiva, a variância da série temporal deve ser constante. Para isso, transformaremos os dados em logaritmo, estabilizando-as, conforme se vê na Figura 1.


Figura 1 - PIB per capita de Alagoas



Fonte: Elaboração própria

Outro pré-requisito para a correta utilização do modelo ARIMA é a transformação da série não estacionária em estacionária. Observando o gráfico 1 novamente, podemos notar que as médias dos dados não são constantes ao longo dos anos. Sendo assim, realizaremos na série original a diferença em primeira ordem, já demonstrada na figura 2.


Figura 2 - LN(PIB per capita de Alagoas) em primeira diferença



Fonte: Elaboração própria

Cumpridos os pré-requisitos para a série temporal, devemos então analisar os correlogramas das funções de autocorrelação e de autocorrelação parcial, com o intuito de determinar um modelo em potencial à série. Auxiliados pelo comando *auto.arima()* presente no pacote *stats* do software R, evidenciou-se que os parâmetros que contemplam o modelo ARIMA são $p=0$, $d=0$, $q=1$.

Figura 3 - Correlogramas de autocorrelação e autocorrelação parcial



Fonte: Elaboração própria

Ao testar o parâmetro através do comando *coefstest()*, do pacote *stats*, evidenciamos o mesmo como significativo. Já para o teste de Ljung-Box, o *p-value* ultrapassa e se encontra entre 0,05 e 0,1.

Figura 4 - Teste dos coeficientes

```
> coeftest(arima(ya1, order=c(0,0,1)))

z test of coefficients:

      Estimate Std. Error z value Pr(>|z|)
mal    -0.4897299  0.1506004  -3.2518  0.001147 **
intercept  0.0140553  0.0032556   4.3173 1.579e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Fonte: Elaboração própria

Figura 5 - Teste de Ljung-Box

```
> Box.test(ya1, type = "Ljung-Box", lag = 1)


Box-Ljung test

data: ya1
X-squared = 3.4615, df = 1, p-value = 0.06281
```

Fonte: Elaboração própria

Analizados os parâmetros a serem utilizados no modelo ARIMA, a próxima etapa a ser realizada é a análise dos resíduos. Através dos correlogramas de autocorrelação residual e de autocorrelação parcial residual, evidenciamos o comportamento aceitável dos resíduos da série.


Figura 6 – Correlogramas de autocorrelação e autocorrelação parcial dos resíduos



Fonte: Elaboração própria

Antes de realizar o teste de normalidade dos resíduos, observa-se a presença de um *outlier* ao plotar o gráfico de probabilidade normal. Retirando a *outlier*, realizamos o teste de Anderson Darling com o auxílio do comando *ad.test()*, do pacote *nortest*. O resultado deste apontou um *p-value* acima de 0,05, e comprova a distribuição normal dos resíduos.

Figura 7 – Gráfico de probabilidade normal dos resíduos



Fonte: Elaboração própria

Figura 8 – Teste de normalidade dos resíduos

```
> testeresidal <- ad.test(log.residal)
> testeresidal

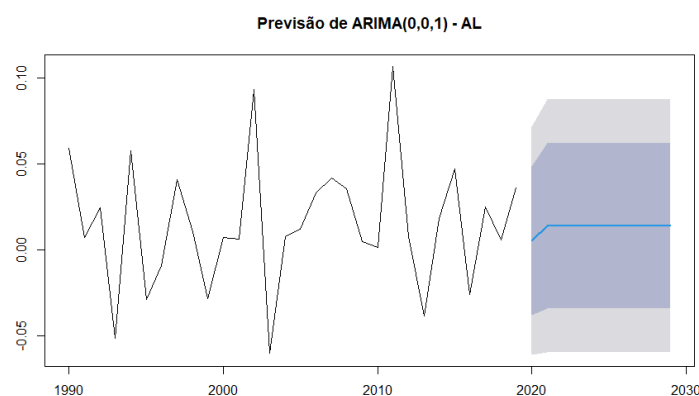
Anderson-Darling normality test

data:  log.residal
A = 0.23632, p-value = 0.7671
```

Fonte: Elaboração própria

Observando a viabilidade dos resultados até então obtidos, realizamos a previsão do PIB per capita alagoano para os próximos 101 anos. Os resultados plotados com base no modelo ARIMA permitem observar o potencial de crescimento do PIB per capita dos respectivos estados. Apesar da reduzida quantidade de observações encontradas, a manipulação destas para o uso no modelo possibilitou ainda assim a previsão do PIB para o estado de Alagoas. A utilização dos parâmetros (0,0,1), ou MA(1), permitiu a estimação de somente um período posterior, vide o fato de que o modelo de Médias Móveis se limita à estimação de períodos em mesma quantidade do número de parâmetros - nesse caso, somente 1 ano após. Evidencia-se na figura 9.


Figura 9 – Previsão do PIB per capita alagoano em logaritmo



Fonte: Elaboração própria

Para o estado de Pernambuco, o modelo ARIMA com parâmetros (1,0,0), ou AR(1), permitiu a estimação da maneira prevista na figura 10.


Figura 10 – Previsão do PIB per capita pernambucano em logaritmo



Fonte: Elaboração própria

Para o estado de São Paulo, os parâmetros para a série estacionária encontrados com o auxílio do comando *auto.arima()* seriam (0,0,0), demonstrando um modelo de ruído branco, sem correlação entre os erros ao longo do tempo.


Figura 11 – Previsão do PIB per capita são-paulino em logaritmo



Fonte: Elaboração própria

Para analisar o crescimento previsto do PIB per capita alagoano em relação aos estados de Pernambuco e São Paulo, os mesmos procedimentos seriam utilizados para a manipulação efetiva do modelo ARIMA: estabilização das variâncias através de logaritmo e estacionarização das séries originais através da diferença em primeira ordem. Porém, dado o nível relativamente inferior de observações em comparação ao desejável para a utilização do modelo (onde atualmente possuímos 31 observações), e dada a característica já estacionária das duas séries temporais seguintes, inviabilizou-se a previsão destas.

Figura 12 – PIB per capita e LN(PIB per capita), de Pernambuco e São Paulo



Fonte: Elaboração própria

Diante da problemática observada, a análise dos correlogramas de autocorrelação e autocorrelação parcial foram prejudicadas. Realizando o teste de raiz unitária (Dickey-Fuller) para os dois estados, com o auxílio do comando *ur.df()* do pacote *urca*, observamos os coeficientes com baixo nível de significância, ainda rejeitando a hipótese nula e apontando uma série estacionária.

4. CONCLUSÕES

O trabalho apresentado teve como objetivo prever e demonstrar os valores futuros pelo método ARIMA, utilizando-se do *software* RStudio.

Devido a não ocorrer a previsão dos dados de Pernambuco e São Paulo, uma vez que as séries temporais correspondentes apresentavam características de estacionaridade em nível, não foi possível realizar a análise sobre quando o PIB per capita de Alagoas ultrapassaria o desses estados.

Para além da reduzida quantidade de observações para o modelo ARIMA, o qual demanda ao menos 70 para uma estimação confiável, e da estacionaridade das séries em nível, o teste de raiz unitária evidencia que para ambas as séries de Pernambuco e São Paulo, tanto o nível de significância dos coeficientes é baixo quanto o valor de *t-stat* resulta na rejeição da hipótese nula de não estacionaridade, confirmando a suspeita anterior. Ao ponto que o modelo ARIMA é um modelo que necessita de séries não-estacionárias, a estatística demonstra a inviabilidade da manipulação dos referidos dados para estimação.

Apesar disso, continuar a seguir os métodos de estimação para as séries impróprias para a mesma permitiu observarmos a forma como se comportam os modelos de RA(1), MA(1) e de Ruído Branco, este último no caso de São Paulo.

Figura 13 – Teste de Dickey-Fuller para Pernambuco

```
> summary(ur.df(pibpcpe))
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
Test regression none

Call:
lm(formula = z.diff ~ z.lag.1 - 1 + z.diff.lag)

Residuals:
    Min       1Q   Median       3Q      Max
-894.30 -149.18   77.83  219.63  692.55

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
z.lag.1      0.006146   0.008652   0.710   0.4836
z.diff.lag  0.312389   0.173031   1.805   0.0822
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 376.5 on 27 degrees of freedom
Multiple R-squared:  0.1575,    Adjusted R-squared:  0.09505
F-statistic: 2.523 on 2 and 27 DF,  p-value: 0.09896

Value of test-statistic is: 0.7103

Critical values for test statistics:
      1pct   5pct 10pct
tau1 -2.62 -1.95 -1.61
```

Fonte: Elaboração própria

Figura 14 – Teste de Dickey-Fuller para São Paulo

```
> summary(ur.df(pibpcsp))
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
Test regression none

Call:
lm(formula = z.diff ~ z.lag.1 - 1 + z.diff.lag)

Residuals:
    Min       1Q   Median       3Q      Max
-1946.96 -437.00  -46.83   420.91 1298.70

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
z.lag.1      0.001788   0.005749   0.311   0.758
z.diff.lag  0.285755   0.168567   1.695   0.102

Residual standard error: 736.3 on 27 degrees of freedom
Multiple R-squared:  0.09889,    Adjusted R-squared:  0.03214
F-statistic: 1.481 on 2 and 27 DF,  p-value: 0.2452

Value of test-statistic is: 0.311

Critical values for test statistics:
      1pct   5pct 10pct
tau1 -2.62 -1.95 -1.61
```

Fonte: Elaboração própria

5. REFERÊNCIAS BIBLIOGRÁFICAS

Econometria de Séries Temporais: Modelo ARIMA parte1. Disponível em <<https://www.youtube.com/watch?v=7CEUfeRCfHU&list=PLMgxefLfK021AUo26VolEMLxqCQU1EK6&index=16>>. Acesso em 19/07/2022.

Teste Anderson-Darling. Disponível em <https://www.ufrgs.br/wiki-r/index.php?title=Teste_Anderson-Darling>. Acesso em 21/07/2022.

Normal Probability Plot of Residuals. Disponível em <<http://www.r-tutor.com/elementary-statistics/simple-linear-regression/normal-probability-plot-residuals>>. Acesso em 18/07/2022.

Curso de Séries Temporais. Disponível em <http://sillasgonzaga.com/material/curso_series_temporais/arima.html#modelos-arima>. Acesso em 12/07/2022.

LIMA, Ricardo. **Séries Temporais em R***. Disponível em <<https://analisemacro.com.br/wp-content/uploads/2015/02/CursoCompleto.pdf>>. Acesso em 13/07/2022.

RIBEIRO, Maria Alice Rosa. **Por que São Paulo passou de uma província pouco importante a uma das mais destacadas regiões agrícolas e industriais do mundo?** Disponível em <<https://www.scielo.br/j/his/a/VHWpfrv5vKy4hfsb9RFNxxv/?lang=pt>>.

GAUDENCIO, Juliana H. D., et. al. **PREVISÃO DE DADOS DE SÉRIES TEMPORAIS DOS PIBS BRASILEIRO E AMERICANO ATRAVÉS DO MODELO ARIMA.** XXXIV ENCONTRO NACIONAL DE ENGENHARIA DE PRODUÇÃO. Disponível em <https://abepro.org.br/biblioteca/enegep2014_TN_STP_200_134_23519.pdf>. Acesso em 15/07/2022.

Em 2019, AL teve a maior safra de cana dos últimos quatro anos, aponta IBGE. Disponível em <<https://www.gazetaweb.com/noticias/economia/em-2019-al-teve-a-maior-safra-de-cana-dos-ultimos-quatro-anos-aponta-ibge/>>. Acesso em 21/07/2022.

Souza, Juliana Cabral Lopes de. **História econômica de Pernambuco: uma síntese das características de sua formação.** Disponível em <https://repository.ufrpe.br/bitstream/123456789/2011/1/tcc_julianacabrallopesdesouza.pdf>

INDICADORES SOCIOECONÔMICOS. Disponível em <http://portal.mec.gov.br/setec/arquivos/pdf/indicad_al.pdf>. Acesso em 21/07/2022.

Sistema de Contas Regionais: Brasil 2019. Disponível em <https://biblioteca.ibge.gov.br/visualizacao/livros/liv101873_informativo.pdf>. Acesso em 21/07/2022.

IPEADATA. Disponível em: <<http://www.ipeadata.gov.br/Default.aspx>>. Acesso em 18/07/2022.

Modelos lineares para séries temporais – ARIMA(p,d,q). Disponível em <https://www.maxwell.vrac.puc-rio.br/3727/3727_4.PDF>. Acesso em 21/07/2022.